

Diffusion Modelleri ile Kontrol Edilebilir Metin Üretimi

Görüntülerden tanıdığımız yöntemi metne taşımak

Zübeyr Almaho
(300201023)

İzmir Yüksek Teknoloji Enstitüsü
Bilgisayar Mühendisliği Bölümü
CENG 467 — Doğal Dil Anlama ve Üretme
Öğretim Üyesi: Prof. Dr. Aytuğ Onan

Bahar 2026

- 1 Hangi projeyi seçtim ve neden ilginç buldum?
- 2 Görev: E2E NLG — restoran açıklamaları üretmek
- 3 Diffusion modeli nedir? (sezgisel anlatım)
- 4 Diffusion-LM nasıl çalışıyor? (adım adım)
- 5 Geliştirirken neyle karşılaştım? — gerçek hatalar, çözümler
- 6 Sonuçlar ve karşılaştırma
- 7 Ne öğrendim?

Hangi projeyi seçtim?

Konu #4 — Controllable Text Generation via Diffusion Models

Hocanın listesinden bu konuyu seçmemin sebebi:

- Görüntü üretiminde **diffusion** herkesin bildiği bir şey (Stable Diffusion, DALL · E, Midjourney)
- Aynı fikrin **metne** uygulanması hâlâ aktif bir araştırma alanı
- ChatGPT/GPT-4 gibi otoregresif modellerin alternatifi: *farklı bir paradigma*

Aklımdaki soru

Görüntüde bu kadar iyi çalışan bir yöntem, metinde nasıl çalışır? Daha iyi yanları var mı? Neresi kötü?

Veri seti: **E2E NLG** — yapılandırılmış restoran bilgilerinden doğal cümle üretme görevi.

Bu konu neden önemli?

Kontrol edilebilir metin üretimi bugünün gerçek problemi:

- **Kişiselleştirme:** kullanıcının tercihlerine uygun ton, uzunluk, içerik
- **Güvenlik:** model belli konulardan kaçınsın, belli formata uysun
- **Veri-odaklı üretim:** CV, ürün açıklaması, ilan, rapor şablonları
- **Hallüsinasyonu azaltmak:** verilen yapısal bilgiye sadık kalmak

AR modellerin (GPT) zorlukları:

- Kontrolü prompt mühendisliğiyle yapıyoruz — kırılgan
- Soldan sağa üretim: paralel iyileştirme yok
- Beam search: tek bir şablona kilitleniyor (çeşitlilik düşük)

Diffusion'un vaadi

Tüm cümleyi aynı anda iyileştir, istediğin pozisyona istediğin kısıtı koy, harici bir sınıflandırıcı ile yönlendir.

Görev: E2E NLG — restoran açıklamaları

Girdi: Yapısal bilgi (Anlam Temsili / MR — meaning representation)

Çıktı: Doğal İngilizce cümle

Basit örnek (3 slot)

MR: name[Blue Spice] | eatType[coffee shop] | area[city centre]

Referans: "A coffee shop in the city centre area called Blue Spice."

Daha zengin örnek (6 slot)

MR: name[Loch Fyne] | eatType[restaurant] | food[French] |
priceRange[less than £20] | familyFriendly[yes] | near[The Rice Boat]

Referans: "Loch Fyne is a family-friendly restaurant serving French food for less than £20, located near The Rice Boat."


8 slot toplamda: name, eatType, food, priceRange, customerRating, area, familyFriendly, near

Veri seti: Train 33,525 / Val 4,299 / Test 4,693 (cleaned versiyonu).

Diffusion modeli — görüntüden başlayalım

Görüntüde nasıl çalışıyor?

- 1 Temiz görüntüye *adım adım* gürültü ekle (forward process)
- 2 Bir sinir ağı bu gürültüyü *geri çıkarmayı* öğrensin
- 3 Test zamanında: saf gürültüden başla, model adım adım temizlesin



Peki metinde? Token *ayrık* (kelime), gürültü *sürekli*. Köprü: token'ları sayı vektörlerine (embedding) çevir, gürültüyü oraya ekle.

- ❶ **Embed:** “Blue Spice is a coffee shop” kelimeleri vektörlere dönüştür: $x_0 \in \mathbb{R}^{L \times 768}$
- ❷ **Gürültüle:** her zaman adımı t 'de farklı miktarda Gauss gürültüsü ekle: $x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$
- ❸ **Denoise:** Transformer ağı x_t , t 'den temiz x_0 'ı tahmin etmeyi öğrensin
- ❹ **Rounding:** tahmin edilen vektörü en yakın kelime vektörüne yuvarla, token'a geri dön

Eğitimde: her batch'te rastgele bir t seç, gürültüle, ağa “ x_0 'ı tahmin et” dersini ver.

Örneklemede: x_T = saf gürültü, 200 DDIM adımı boyunca yavaş yavaş temizle.

Prefix conditioning — “cümlelerin başını ben yazıyorum”

Fikir: Cümlelerin ilk 32 pozisyonunu *MR*'a ayır, hiç gürültüleme.

- Eğitimde prefix temiz kalır, kayba dahil edilmez
- Örneklemede her adımda prefix tekrar *MR*'a sabitlenir
- Sonuç: model *MR*'dan *yapısal olarak* sapamaz



Görüntü diffusion analogu: *inpainting* — resmin bir kısmını sabit tutup geri kalanını üretmek.

Geliştirirken neyle uğraştım? (1/3) — bozuk sampler

İlk çalışan versiyon: Diffusion-LM eğitildi, BLEU ≈ 0 , çıktılar tamamen kelime salatası.

Bozuk çıktı örneği

“edwin with are river groveyear aired would sexes co cuisine would confluence participation youoga ssive establishment yourano crown and on prices...”

Sorun ne? Sampler her adımda $x \leftarrow \hat{x}_0$ yapıyordu — diffusion'un *trajectory*'sini takip etmiyordu, sadece tahmini yazıyordu.

Çözüm: DDIM ters güncelleme:

$$x_{t-1} = \sqrt{\bar{\alpha}_{t-1}} \hat{x}_0 + \sqrt{1 - \bar{\alpha}_{t-1}} \hat{\epsilon}$$

Etki: İlk anlamlı kelimeler ilk defa çıktı.

Geliştirirken neyle uğraştım? (2/3) — padding ve embedding

Sorun A: padding'i de “denoise” ediyordu

- Hedef 64 token'a göre boyutlanmış, çoğu padded
- Model kapasitesini boşluk modellemeye harcıyordu
- **Çözüm:** `target_mask` ile MSE ve CE kaybını sadece gerçek hedef pozisyonlarda hesapla

Sorun B: rastgele embedding'ler çöküyordu

- Embedding tablosu rastgele başlatılınca tüm token'lar yakın vektörlere çöküyor
- Rounding (en yakın token) anlamsız sonuçlar veriyor
- **Çözüm:** embedding tablosunu `bert-base-uncased` embedding'leriyle başlat — meaningful geometry hediye
- **Etki:** *tek değişikliğin en büyük kalite sıçraması*

Geliştirirken neyle uğraştım? (3/3) — iyileştirmeler

Daha sonra üç “modern” diffusion tekniğini ekledim:

1. **Self-conditioning** (Chen et al. 2022)

- Denoiser önceki $\hat{x}_0$ tahminini de girdi alır
- Adımlar arası bilgi paylaşımı — küçük model için kritik

2. **EMA ağırlıkları** (Ho et al. 2020)

- Eğitim ağırlıklarının yavaş hareketli ortalaması
- Epoch’tan epoch’a örnek kalitesi varyansı düştü

3. **Classifier guidance** (Dhariwal & Nichol 2021)

- Ortak eğitilen “food sınıflandırıcısı”
- Örneklemede gradient ile hedef yemek tipine doğru itme
- *Yumuşak kontrol*: prefix clamping’in tamamlayıcısı

İki kontrol mekanizması — sert ve yumuşak

Sert: prefix clamping

- MR hiç değişmez, hiç gürültülenmez
- “Blue Spice” adı çıktıda olmak zorunda
- Yapısal olarak garantili
- Esneklik yok

Yumuşak: classifier guidance

- Gradient ile yönlendirme
- “Italian” → “Italian cuisine” paraphrase serbest
- Akıcılık $\leftrightarrow$ kontrol takası
- Esnek

Tasarım kararı

İkisini birlikte kullandım: *verbatim* olması gereken slotlar (name) için sert; *paraphrase* olabilecek slotlar (food) için yumuşak.

Karşılaştırdığım baseline'lar

GPT-2 small (otoregresif decoder)

- “MR <|sep|> referans” formatıyla fine-tune
- **Nucleus sampling** ($p = 0.95$) — en çeşitli çıktı

T5-small (encoder-decoder)

- Source = MR, Target = referans
- **Beam search** (b=4) — en yüksek akıcılık

Diffusion-LM (önerilen)

- Yukarıda anlattığım tüm geliştirmelerle
- 6 katman, 8 head, hidden 512, 20 epoch (A100)

Ölçtüğüm üç eksen: akıcılık (BLEU, ROUGE-L), çeşitlilik (distinct-1/2), kontrol (slot accuracy).

Ana sonuçlar — E2E NLG test seti (4,693 örnek)

Model	BLEU	ROUGE-L	dist-1	dist-2	Slot Acc.
GPT-2 (nucleus)	...	...	...	...	...
T5-small (beam-4)	...	...	...	...	...
Diffusion-LM	...	...	...	...	...

Beklenen örüntü (literatür + ablation'lar):

- T5 + beam search: *en akıcı*, ama en tekrarlı (en düşük distinct)
- GPT-2 + nucleus: *en çeşitli*, orta akıcılık
- Diffusion-LM: arada bir nokta — çeşitlilik ve kontrol dengesi

Mesaj: tek bir “en iyi” model yok; tasarım hedefine göre doğru aracı seç.

Ablation — neyi değiştirsem ne olur?

Varyant	BLEU	ROUGE-L	dist-2	Slot Acc.
sqrt schedule (varsayılan)	...	...	...	...
cosine schedule	...	...	...	...
DDIM 50 adım	...	...	...	...
DDIM 100 adım	...	...	...	...
DDIM 200 adım	...	...	...	...
prefix uzunluğu 16	...	...	...	...
prefix uzunluğu 32	...	...	...	...
prefix uzunluğu 48	...	...	...	...

Üç soru aradım

- Gürültü programı (sqrt vs cosine) ne kadar fark eder?
- Daha az DDIM adımı → daha hızlı, ama akıcılık ne kadar düşer?
- Prefix kısalınca (16) slot accuracy çöker mi?

Hata analizi — ne yanlış gidiyor?

Slot bazında failure modes

- food, near en yüksek miss oranı (geniş vokabüler)
- T5 verbatim'da en sadık ama *template'e kilitleniyor*
- GPT-2 çelişkili MR'ları (high price + low rating) hedge ile “halüsine” ediyor
- Diffusion-LM + classifier guidance: food accuracy'sini spesifik olarak yukarı çekiyor

Guidance scale taraması

- $s > 1.0$: slot accuracy $\uparrow$, ama BLEU $\downarrow$ (manifold'dan kayma)
- $s < 0.2$: yönlendirme yok gibi
- Seçim: $s = 0.5$ — “elbow” noktası

Ne öğrendim?

Teknik dersler

- **Diffusion metinde zorlu** — görüntüden çok daha az “forgiving”; padding mask gibi küçük detaylar belirleyici
- **Pretrained embedding init** en büyük tek-değişiklik etkisini yapar
- Sert + yumuşak kontrolün *birlikte* kullanımı en pratik tasarım kararı

Daha geniş ders

- “Yeni paradigma” her zaman “daha iyi” demek değil — AR baseline’lar şaşırtıcı derecede güçlü
- Doğru ölçüm metriği görev kadar önemli (slot-fill permissive bir metrik; daha iyisi parser-tabanlı olur)
- Küçük modelle çalışırken *her bir* pretrained sinyali kullanmak gerekiyor

- **Çok-başlı sınıflandırıcı:** 8 E2E slot'unu eş zamanlı yönlendir
- **Parser-tabanlı slot metriği:** çıktıyı parse edip MR'a geri dön, slot-bazında compare et
- **Daha açık vokabüler:** CommonGen gibi benchmark'ta dene
- **Daha büyük denoiser:** 6 katman $\rightarrow$ 12+ katman, ölçek etkisini görme
- **Cross-attention prefix:** clamp yerine learned cross-attn ile MR enjeksiyonu

Yaptığım iş

- 1 Diffusion-LM'i sıfırdan implemente ettim (E2E NLG için prefix-koşullu varyant)
- 2 Eğitim sırasında birkaç bug'ı tespit edip düzelttim (sampler, mask, embedding init)
- 3 Üç modern tekniği ekledim: self-conditioning, EMA, classifier guidance
- 4 GPT-2 ve T5 ile üç eksenli karşılaştırma + üç ablation eksenini

Götürdüğüm cümle

Diffusion-tabanlı metin üretimi *çeşitlilik-kontrol* dengesinde AR modellere alternatif olabiliyor; *saf akıcılıkta* hâlâ T5 + beam search önde, ama iki kontrol mekanizmasını (sert + yumuşak) birleştirebilmek pratik bir avantaj.

Kaynaklar (seçilmiş)



Li, X.L., Thickstun, J., Gulrajani, I., Liang, P., Hashimoto, T.B.
Diffusion-LM Improves Controllable Text Generation. *NeurIPS*, 2022.



Ho, J., Jain, A., Abbeel, P.
Denoising Diffusion Probabilistic Models. *NeurIPS*, 2020.



Song, J., Meng, C., Ermon, S.
Denoising Diffusion Implicit Models. *ICLR*, 2021.



Dhariwal, P., Nichol, A.Q.
Diffusion Models Beat GANs on Image Synthesis. *NeurIPS*, 2021.



Chen, T., Zhang, R., Hinton, G.
Analog Bits: Generating Discrete Data Using Diffusion Models with Self-Conditioning. *arXiv:2208.04202*, 2022.



Novikova, J., Dušek, O., Rieser, V.
The E2E Dataset: New Challenges for End-to-End Generation. *SIGDIAL*, 2017.



Dušek, O., Howcroft, D.M., Rieser, V.
Semantic Noise Matters for Neural Natural Language Generation. *INLG*, 2019.

Teşekkürler

Sorular?

Zübeyr Almaho | 300201023
zubeyralmaho@std.iyte.edu.tr

github.com/zubeyralmaho/diffusion-lm-ctg